一、 数据清洗和特征处理方法

1. 缺失值处理：

· 年龄：缺失较少，考虑到存在极端值，采用中位数填补

· 登船港口：只缺了两个，采用众数填补。

· 客舱：基本都缺失，这一列都删了

2. 特征工程：

· 性别：模型无法识别文本内容，所以将女性(male)映射为 0，男性(female)映射为 1，然后才能识别

· 登船港口：用了独热编码，生成 Embarked_C、Embarked_Q、Embarked_S 三列，防止将其简单的映射为 123，让模型产生它们三个之间有大小关系的错觉

· 姓名：原始名字无意义，所以一开始本来想直接删掉，但后来结果不是很好，所以就没删，把其中一部分当成一个新的特征，利用正则表达式提取其中的称谓（Mr, Mrs, Miss, Master 等），并归类为 1-5 的数字。称谓是隐藏的强特征，直接暴露了乘客的性别、年龄和阶级

· SibSp + Parch：这个是一个自己组合创造新特征 FamilySize（家庭规模），帮助模型捕捉“中等规模家庭生存率最高”的复杂规律

二、 模型结构、损失函数、优化器及主要超参数

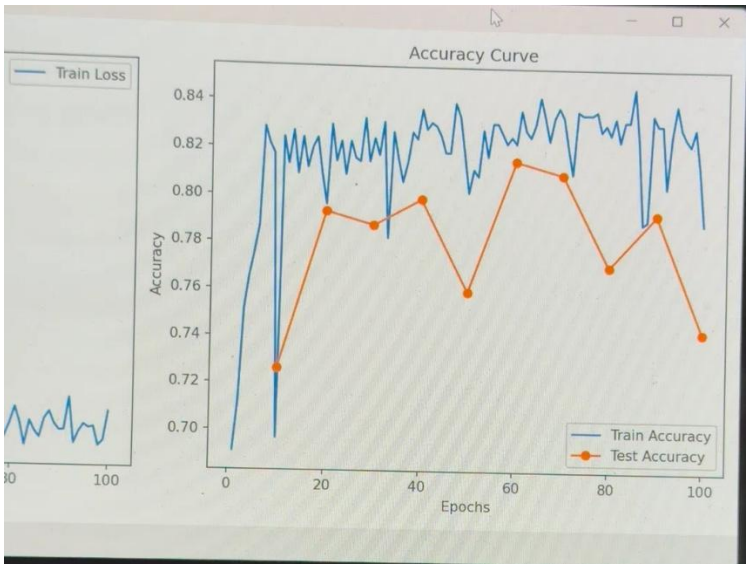
1. 模型结构：使用 PyTorch 自定义 nn.Module 的全连接神经网络（MLP）。

· 输入层：10 个神经元（对应 10 个特征）

· 隐藏层：1 层，包含 16 个神经元，激活函数为 ReLU

· 输出层：1 个神经元，激活函数为 Sigmoid（输出 0-1 之间的生存概率）

2. 损失函数：nn.BCELoss()（二分类交叉熵损失），但是一开始测试集准确率不高而且波动特别大（见下图）所以选择将损失函数 L2 正则化（weigh_decay=1e-4）



3. 优化器：Adam，学习率 lr=0.001（本来设置的是 0.01，后来发现好像有点大，取 0.01 时得到结果见上图）

4. 主要超参数：训练轮次 Epochs = 100，批次大小 Batch Size = 32

三、 数据划分方式、随机种子和实验配置

· 数据划分：将数据按 8:2 划分为训练集和测试集（本来还想加个验证集提高模型的准确率，但能力不太支持）

· 随机种子：设置全局随机种子 SEED=42。这是为了固定数据划分的切分方式,确保实验的可复现性

· 实验配置：在 pytorch 虚拟环境下运行所有核心逻辑被拆分为 data_preprocessing.py, model.py, train.py, predict.py 四个模块

四、 训练过程中遇到的问题及解决方法

1. 环境冲突问题：

终端直接运行 python train.py 时报错，解决方法：发现默认使用了 base 环境，通过 conda activate pytorch 成功切换环境后解决。

2. 张量类型转换错误：数据传入 PyTorch 时报错_。解决方法：强制使用 .astype(np.float32) 转换数据类型。

3. 模型维度不匹配：

运行 predict.py 时报 size mismatch for fc1.weight。解决方法：排查发现训练集输入维度为 10，而预测时输入是 9，补齐特征数量后解决。

4. 底层库损坏：中途遇到诡异的 torch has no attribute 'version' 报错，排查后发现

PyTorch 底层文件残缺，通过卸载并重新使用镜像源完整安装解决。

五、 测试集准确率、实验结果分析和心得体会

· 测试集准确率：在 Epoch 50 以后只有一些小波动，变化不大

· 结果分析：

如图所示，蓝色的训练集准确率稳定在 0.8 以上，橙色的测试集准确率在 0.75 以上。模型在训练集上的表现优于测试集，说明出现了轻微的“过拟合”现象

然后可能是我对这个模型有的一些改进的想法，比如那个表格里面有的人是一家的，可以根据姓氏将一组人分到一块，然后将一个姓氏的人一个家庭全分在训练集或者全分在测试集，因为如果完全随机分的话可能会存在数据泄露问题，比如哥哥和弟弟，哥哥在训练集，弟弟在测试集，然后模型在训练集中发现了哥哥已经死亡，所以有可能会导致模型在测试集中看到了同姓的弟弟，直接预测已经死亡。然后现在跑出来的模型感觉不是很准确，可以多加几个隐藏层，再让几个神经元随机失效，感觉这样可以提高准确率

然后还有一点就是说这个模型的部分代码是 ai 帮忙写的（比如那个画图），还有就是自己手搓参考了一点吴恩达老师有一节课就是专门讲如何直接用 phython 手搓出来，结果有的地方不太对报错，然后 ai 改的，所以说这么多代码都是要自己记住吗